

Rapport qualite des donnees

Dataset medical prepare pour le fine-tuning LoRA

Initial 256 916 lignes brutes	Final 246 238 conversations valides	Conservation 95,84 % apres nettoyage	Validation OK 0 probleme final
-------------------------------------	---	--	--------------------------------------

1. Synthese du livrable

Le notebook a permis de transformer un dataset medical brut de 256 916 lignes en un dataset final de 246 238 conversations valides. Les controles finaux affichent 0 probleme sur les champs vides, les doublons et les seuils de longueur. Le dataset est donc pret a etre depose comme livrable et utilise pour une preparation LoRA.

Au total, 10 678 lignes ont ete retirees, soit 4,16 % du dataset initial. Le taux de conservation est de 95,84 %.

Ce rapport est volontairement synthetique : il garde uniquement les elements necessaires pour justifier la qualite du dataset et son depot comme livrable.

Les resultats detailles, les sorties completes et les etapes d'execution restent disponibles dans le notebook.

Decision qualite : dataset valide pour livraison.

2. Donnees analysees

Element	Resultat
Fichier source	dialogues.parquet
Colonnes initiales	Description, Patient, Doctor
Volume	256 916 lignes - 3 colonnes

3. Nettoyage et controles appliques

Les traitements ont ete limites aux etapes utiles pour garantir la qualite du dataset et preparer son exploitation en fine-tuning LoRA :

Controle	Traitement applique
Standardisation	Noms de colonnes en minuscules : description, patient, doctor
Nettoyage texte	Passage en minuscules, suppression des retours ligne, tabulations et espaces multiples
Lignes vides	Conservation uniquement des conversations avec patient et doctor non vides
Qualite conversation	Question entre 20 et 4000 caracteres, reponse entre 30 et 6000 caracteres
Doublons	Suppression des doublons sur description + patient + doctor

4. Resultats chiffres du traitement

Etape	Avant	Apres	Supprimees	Commentaire
Conversations vides	256 916	256 916	0	Aucune ligne vide critique
Filtrage qualite	256 916	256 616	300	0,12 % du volume initial
Doublons	256 616	246 238	10 378	4,04 % du volume controle
Bilan final	256 916	246 238	10 678	4,16 % retire au total

5. Validation finale de la qualite

La validation finale du notebook montre que toutes les regles qualite sont respectees. Aucun probleme residuel n'a ete detecte.

Contrôle final	Nombre de problemes	Statut
Questions patient vides	0	OK
Reponses doctor vides	0	OK
Doublons description + patient + doctor	0	OK
Questions trop courtes	0	OK
Reponses trop courtes	0	OK
Questions trop longues	0	OK
Reponses trop longues	0	OK

Interpretation : le dataset final ne contient plus de conversations vides, trop courtes, trop longues ou dupliquees selon les criteres definis. Il est coherent pour la suite du projet.

6. Preparation pour le fine-tuning LoRA

Le dataset final a ete converti au format instruction / input / output, format adapte a l'apprentissage supervise avec LoRA. Le modele recoit une consigne et une question contextualisee, puis apprend a reproduire la reponse medicale attendue.

Element	Resultat
Volume LoRA	246 238 lignes - 3 colonnes
Colonnes creees	instruction, input, output
instruction	Consigne donnee au modele
input	Contexte medical + question du patient
output	Reponse du medecin

7. Separation train/test 80/20

Dataset	Train	Test	Ratio train	Ratio test
Dataset nettoye	196 990	49 248	80,00 %	20,00 %
Dataset LoRA	196 990	49 248	80,00 %	20,00 %

Le split a ete effectue apres nettoyage afin que les fichiers train et test contiennent uniquement des conversations validees.

8. Missions couvertes

Mission demandee	Statut	Preuve
Tests de qualite des conversations	Realise	Longueurs, valeurs vides, doublons et conversations rejetees
Analyse et nettoyage du dataset medical	Realise	Standardisation, nettoyage texte, suppression des donnees non conformes
Preparation des donnees pour le fine-tuning LoRA	Realise	Creation du format instruction / input / output
Validation de la qualite des conversations medicales	Realise	Controles finaux avec 0 probleme

9. Visualisations de qualite

Les graphiques suivants ont ete ajoutes pour valoriser les resultats du notebook et rendre le rapport plus lisible. Ils montrent l'evolution du dataset, les causes de suppression, la repartition des longueurs, la validation finale et le split train/test.

Figure 1 - Evolution du nombre de lignes apres nettoyage.




Figure 1 - Evolution du nombre de lignes apres nettoyage.

Interpretation : le volume diminue de 256 916 lignes a 246 238 conversations valides, principalement apres suppression des doublons.

Figure 2 - Nombre de lignes supprimees par type de probleme.




Figure 2 - Nombre de lignes supprimees par type de probleme.

Interpretation : les doublons representent la principale source de suppression, avec 10 378 lignes retirees.

Figure 3 - Distribution des longueurs des questions patient.




Figure 3 - Distribution des longueurs des questions patient.

Figure 4 - Distribution des longueurs des reponses doctor.




Figure 4 - Distribution des longueurs des reponses doctor.

Figure 5 - Comparaison des longueurs des questions et des reponses.




Figure 5 - Comparaison des longueurs des questions et des reponses.

Figure 6 - Validation finale des controles qualite.




Figure 6 - Validation finale des controles qualite.

Interpretation : tous les controles finaux indiquent 0 probleme detecte.

Figure 7 - Repartition du dataset nettoye en train/test.




Figure 7 - Repartition du dataset nettoye en train/test.

Figure 8 - Repartition du dataset LoRA en train/test.




Figure 8 - Repartition du dataset LoRA en train/test.

10. Livrables a déposer

Livrable	Utilite
dialogues_cleaned.parquet	Dataset medical nettoye au format Parquet
dialogues_cleaned.csv	Dataset medical nettoye au format CSV
dialogues_lora.csv	Dataset prepare pour LoRA au format CSV
train_cleaned.csv / test_cleaned.csv	Split 80/20 du dataset nettoye
train_lora.csv / test_lora.csv	Split 80/20 du dataset LoRA
rapport_qualite_donnees.pdf	Rapport de qualite des donnees a déposer
Dossier figures	Graphiques de validation et d'analyse qualite

11. Conclusion

Le traitement realise repond aux missions demandees. Le dataset final contient 246 238 conversations medicales validees, sans doublons, sans champs critiques vides et sans conversation hors seuil. La preparation LoRA a egalement ete realisee avec 246 238 exemples au format instruction / input / output.

Le rapport qualite confirme que les livrables principaux sont prêts : le dataset medical nettoye, le dataset LoRA, les fichiers train/test, les graphiques et le rapport de qualite des donnees.

Indicateur final	Valeur
Dataset final	246 238 conversations valides
Validation qualite	0 probleme detecte
Format LoRA	246 238 exemples instruction / input / output
Train/Test	196 990 / 49 248
Decision	Valide pour livraison